

Sprawozdanie 2: Sieci Kohonena

Autor:

Mateusz Stączek

Maj, 2022

Nr indeksu:

305757

Temat Laboratoriów

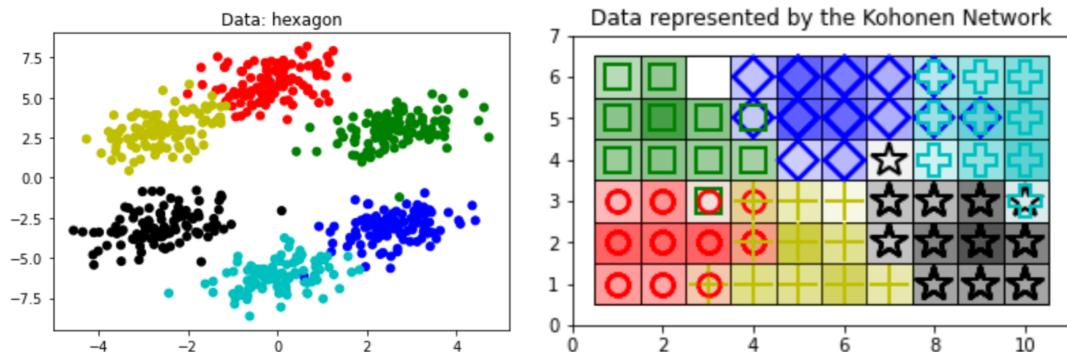
Własna implementacja prostej sieci Kohonena. Celem laboratoriów jest uzyskanie dobrych wyników na prostych zbiorach danych oraz na zbiorach MNIST i innych, a także wizualizacja efektów procesu uczenia.

Wykonana praca i wyniki eksperymentów

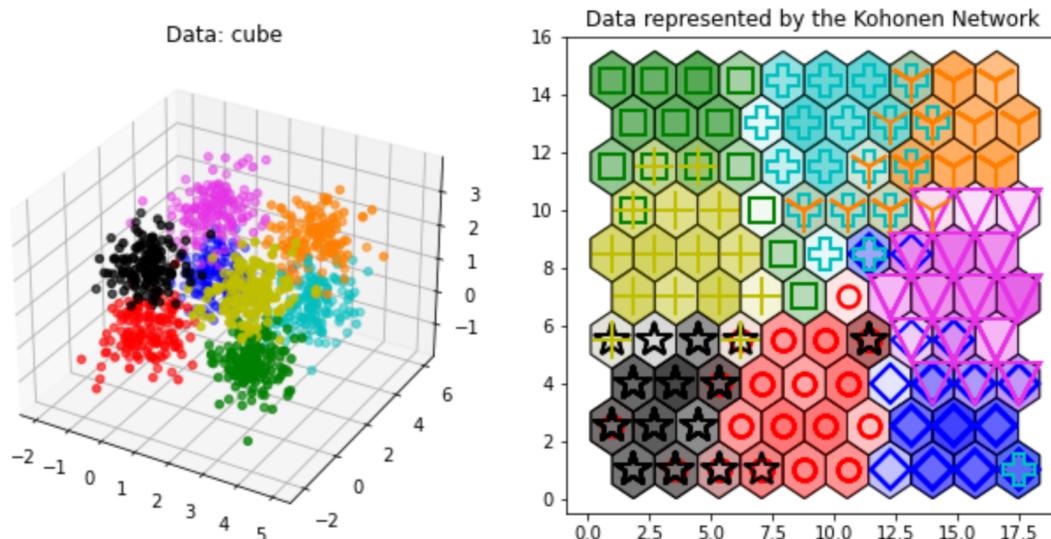
Zaimplementowana została sieć Kohonena złożona z neuronów ułożonych na siatce prostokątnej oraz sześciokątnej. Dostępne funkcje sąsiedztwa to funkcja gaussowska oraz minus druga pochodna funkcji gaussowskiej. Oznaczenia - kolory odpowiadają klasom, natomiast kształty pojedynczym punktom z danych (pomaga zobaczyć, że coś się nakłada).

Laboratorium 1

Dla danych 2d się dobrze sprawdziło:

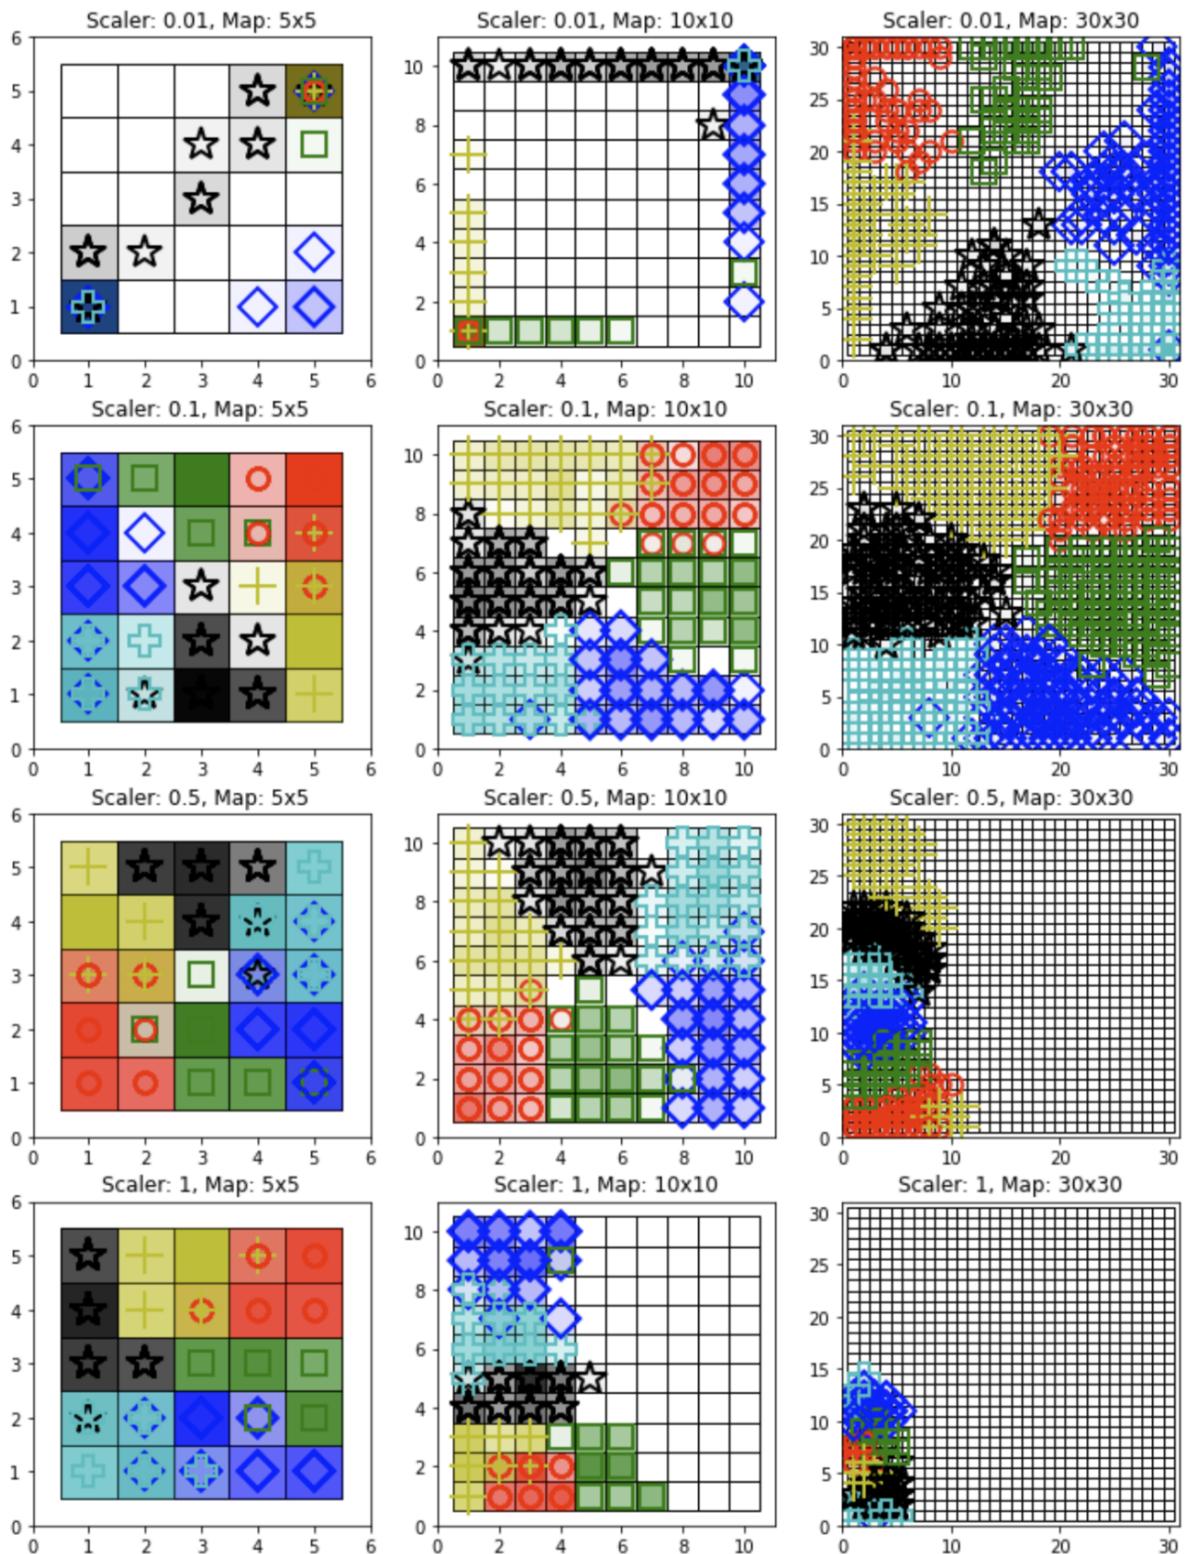


Dla danych 3d też się sprawdza:



Porównanie różnych rozmiarów sieci oraz różnego parametru skalującego odległości:

Data: hexagon, 10 epochs, learning rate 0.3



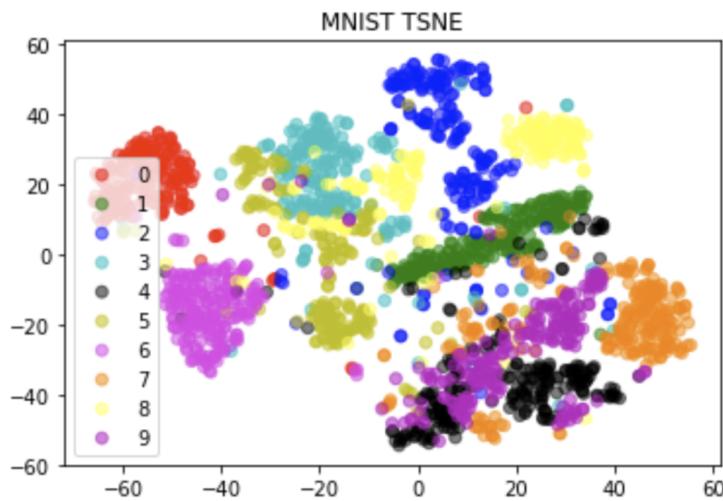
Uzyskane wyniki pozwalają wyciągnąć wniosek, że większa sieć nie jest potrzebna (w przeciwieństwie do sieci neuronowych, gdzie dodanie warstw często pomaga). Ponadto, są przypadki, gdy reprezentacja danych jest dość pusta, tzn wiele neuronów nie leży najbliżej

dowolnej obserwacji. Jak widać, niezbędne jest znalezienie odpowiednich parametrów, aby lepiej odwzorować znalezione clusters.

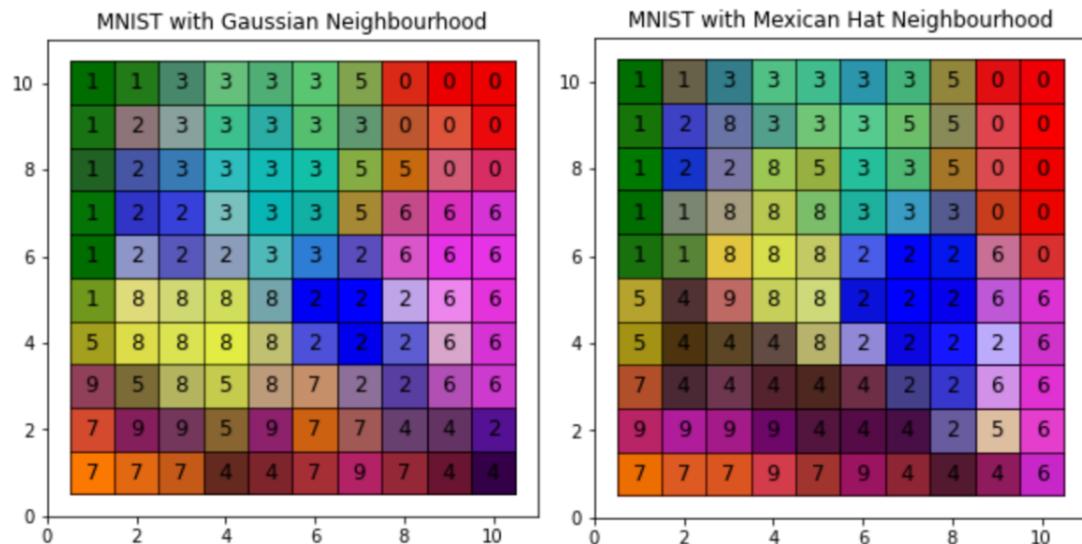
Laboratorium 2

Wykorzystane dane to MNIST i zbiór dot. aktywności człowieka zapisanych wg odczytów z czujników telefonu.

Zbiór 1 - MNIST

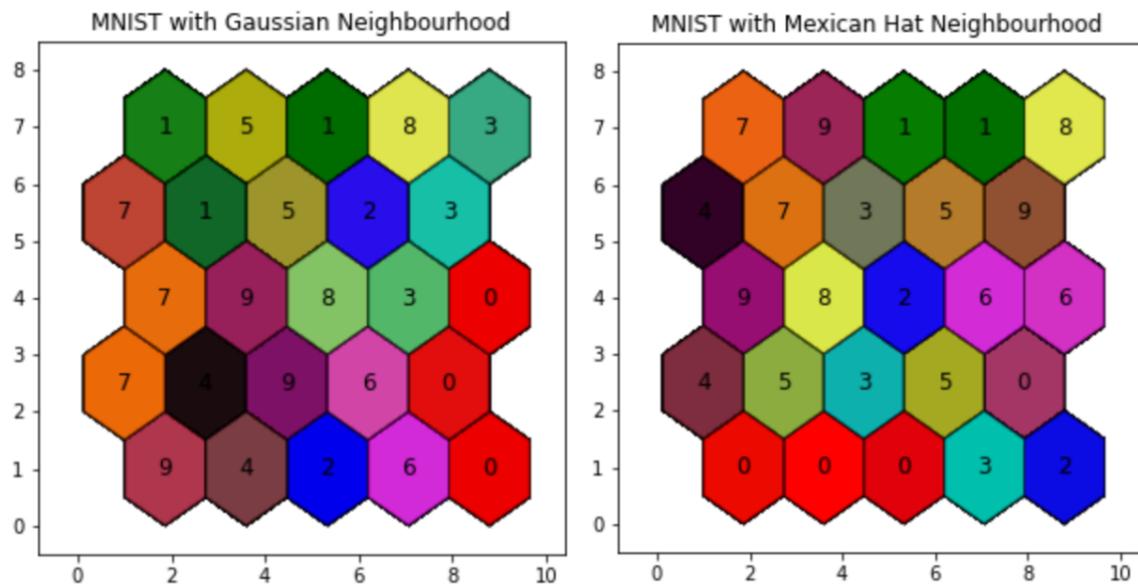


Klasy (cyfry) ze zbioru MNIST zostały w miarę dobrze oddzielone poniżej przez obie architektury, przy różnych kształtach i rozmiarach sieci. Zmiana neighbourhood function z gaussian na mexican hat niewiele zmieniła (przy takich, a nie innych parametrach).



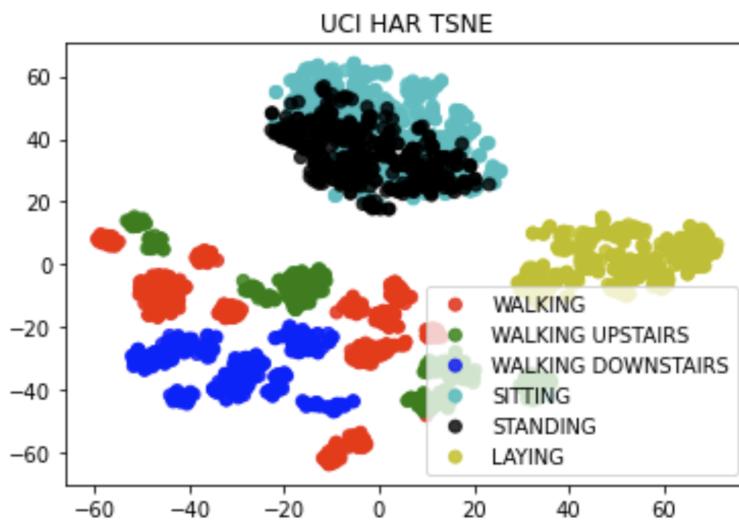
Co ciekawe, np na lewym obrazku widać, że neurony przedstawiające 6 oraz 0 są koło siebie. Podobnie na prawym obrazku widać, że 3 leży między 5 i 8. Można doszukiwać się w nich sąsiedztwa odwzorowania podobieństwa kształtów.

Dla siatki sześciokątnej rezultaty były podobne.



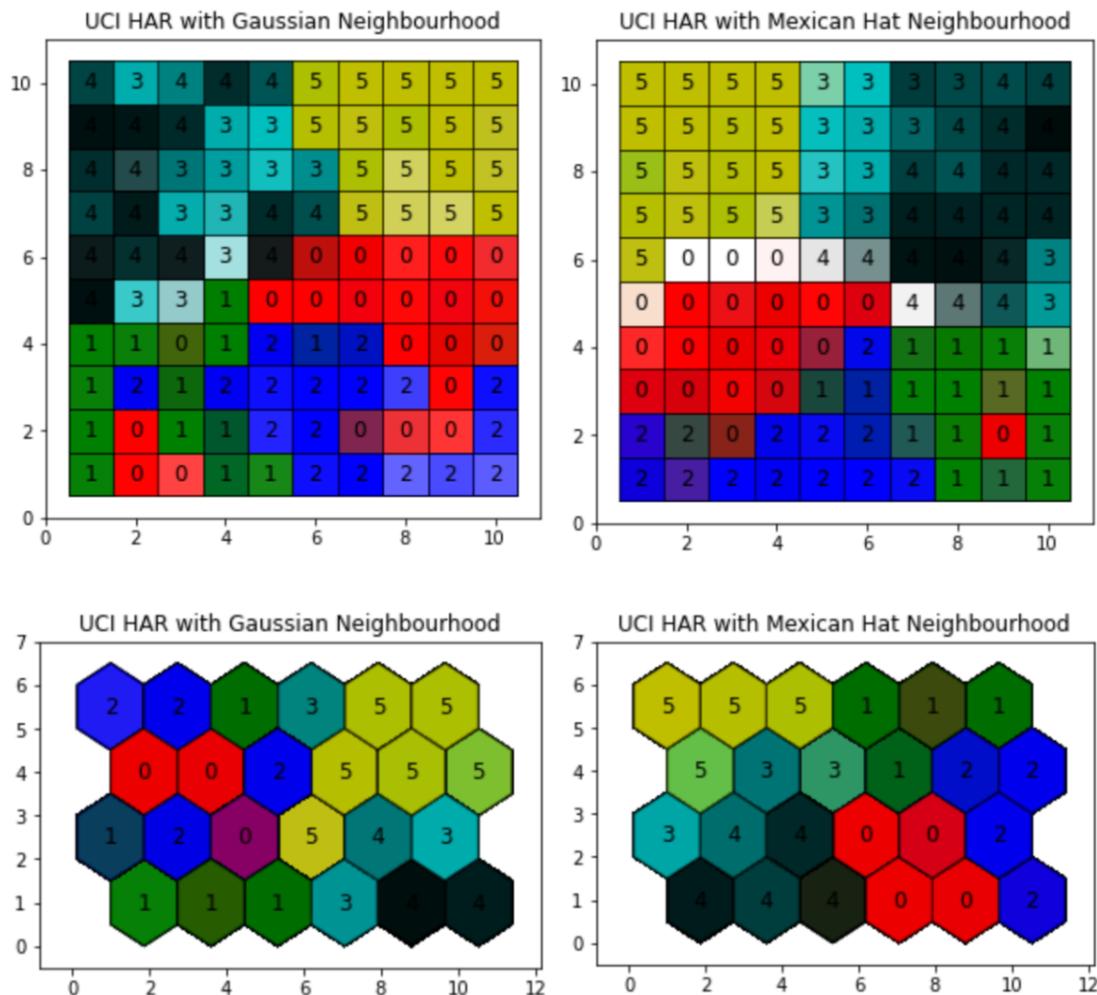
Gdyby zmienić odpowiednio parametr odpowiadający odległości oraz zwiększyć sieć, można by otrzymać rezultaty jak w kolejnym punkcie, tzn prawie puste neurony.

Zbiór 2 - Aktywności człowieka



Drugi zbiór zawiera 6 klas - 3 wymiesiane ze sobą odpowiadają za chodzenie, 2 praktycznie się pokrywające za stanie/siedzenie, a jedna dobrze oddzielona od pozostałych za leżenie. Samo TSNE daje pewne rozróżnianie, które z nich są dobrze odróżnialne, a które nie.

Dla obu wariantów sieci i funkcji sąsiedztwa rezultaty to:



Oznaczenia:

- 0 - chodzenie (czerwone),
- 1 - chodzenie po schodach do góry (zielone),
- 2 - chodzenie po schodach w dół (niebieskie),
- 3 - siedzenie (biało-niebieskie),
- 4 - stanie (czarne),
- 5 - leżenie (żółte).

Jak widać, rezultaty podzielenia danych przez wszystkie warianty architektur sieci są zbliżone do rezultatów przedstawionych przez TSNE - leżenie (żółte) jest dobrze oddzielone od pozostałych klas, natomiast siedzenie (biało-niebieskie) oraz stanie (czarne) są praktycznie nieroróżnialne.

Co ciekawe, udało się tak ustawić parametry, aby przy dość sporej siatce kwadratów z funkcją mexican hat otrzymać kilka dość pustych pikseli. Świadczy to może o sporej odległości pomiędzy leżeniem (5, żółte), a chodzeniem (0, czerwone).

Podsumowanie

Sieci Kohonena (również - Self Organizing Maps) są dobrym i prostym narzędziem do sprawdzenia, czy w danych występują pewne klastry. Dodatkowo, sąsiednie neurony odpowiadają pewnemu sąsiedztwu danych rzeczywistych - doskonale widoczne w danych MNIST, gdzie można sobie tłumaczyć bliskość 0 i 6 poprzez podobieństwo obu z tych cyfr.

Warto mieć na względzie to, że nie zawsze poszczególne klasy są możliwe do oddzielenia - przykładowo po odczytach z czujników telefonu trudno stwierdzić, czy ktoś stoi czy siedzi.

W zależności od ustawionych parametrów oraz z pomocą funkcji sąsiedztwa Mexican Hat zamiast domyślnej Gaussian, uzyskać łatwiej można większe odległości między neuronami, a przez to i neurony dość puste i podkreślające różnicę między klasami (leżenie vs chodzenie).